ANALISIS BIG DATA WEB SCRAPING



DISUSUN OLEH: FIQQI AHLUDZIKRI (2111010034)

DOSEN:

Dr. M. SAID HASIBUAN

FAKULTAS ILMU KOMPUTER PROGRAM STUDI TEKNIK INFORMATIKA INSTITUT INFORMATIKA DAN BISNIS DARMAJAYA BANDAR LAMPUNG TAHUN AJARAN 2023/2024

MENCARI TINGKAT KEBAHAGIAAN DI SETIAP NEGARA



Keterangan: Import beberapa library, requests untuk akses website yang akan diambil data, pandas untuk mengolah data, seaborn dan maplotlib untuk visualisasi data, dan bautifulsoup untuk memudahkan proses scraping.

Requests.get: untuk mengambil data dari website wikipedia

```
[10] continents_countries_soup = bs4(continents_page,"lxml")
    continents = continents_countries_soup.find_all('h2' > 'span', {"class":"mw-headline"})
    continents

[<span class="mw-headline" id="Africa">Africa</span>,
        <span class="mw-headline" id="Antarctica">Antarctica</span>,
        <span class="mw-headline" id="Asia">Asia</span>,
        <span class="mw-headline" id="Europe">Europe</span>,
        <span class="mw-headline" id="South_America">North America</span>,
        <span class="mw-headline" id="South_America">South America</span>,
        <span class="mw-headline" id="South_America">South America</span>,
        <span class="mw-headline" id="Oceania">Oceania</span>,
        <span class="mw-headline" id="Oceania">Oceania</span>,
        <span class="mw-headline" id="Other_websites">Other websites</span>]
```

Keterangan: memfilter nama benua dari website denagan beatifulsoup

```
[11] unwanted_words = ["Antarctica", "References", "Other websites"]
target_continents = [continent.text for continent in continents if continent.text not in unwanted_words]
target_continents

['Africa', 'Asia', 'Europe', 'North America', 'South America', 'Oceania']
```

Keterangan: unwanted_word: untuk menampung kata-kata yang tidak relevan dan variable continents untuk menampung nama-nama benua yang diperlukan.


```
ol html = continents_countries_soup.find_all('ol')
all_countries = [countries.find_all('li',{"class": None, "id": None}) for countries in ol_html]
all_countries

[{| (ali><a href="/wiki/Algeria" title="Algeria">Algeria</a> - <a href="/wiki/Algiers" title="Algiers">Algiers</a> - <a href="/wiki/Algiers" title="Algiers">Algiers</a> - <a href="/wiki/Algiers" title="Luanda">Luanda</a> - <a href="/wiki/Angola" title="Benin">Benin</a> - <a class="mw-redirect" href="/wiki/Porto_Novo" title="Porto Novo">Porto Novo</a>,
<a href="/wiki/Cotonou" title="Cotonou">Cotonou</a> / (ali><a href="/wiki/Botswana" title="Botwana">Botswana</a> - <a href="/wiki/Gaborone" title="Gaborone">Gaborone</a> / (ali><a href="/wiki/Burkina Faso" title="Burkina Faso">Burkina Faso</a> - <a href="/wiki/Gaborone" title="Gaborone">Gaborone</a> / (ali><a href="/wiki/Burundi" title="Burundi">Burundi</a> - <a href="/wiki/Gitega" title="Gitega">Gitega</a> - <a href="/wiki/Gaborone" title="Gaborone">Gaborone</a> / (ali><a href="/wiki/Gaborone")</a> / (ali><a href="/wiki/Gaborone")</a> / (ali><a href="/wiki/Gaborone")</a> / (also spelled Cameroun) - <a href="/wiki/Yaound%</a> / (ali><a href="/wiki/Yaound%</a> / (also spelled Cameroun) - <a href="/wiki/Yaound%</a> / (also href="/wiki/Yaound%</a> / (
```


Keterangan: Mengambil nama-nama negara dari halaman website dengan memfilter ol_html dan li



Keterangan: memfilter nama negara dengan membuat loop disetiap item pada variable all_countries, variable countries berisi nama-nama negara di benua yang sama, di dalam items ada daftar element html yang akan difilter. Setelah di filter akan masuk dalam variable countries_in_continents.



Keterangan: menampilkan data dengan print data frame.



Keterangan: menggunakan metode explode untuk memisahkan setiap negara dengan baris yang berbeda.

Keterangan: Mengambil data tingkat kebahagiaan tiap negara.

```
        Countries_score_df
        = pd.read_html(str(countries_score_table))

        Countries_score_df
        Country or region of the point of the
```


Keterangan: Memproses data menggunakan metode pandas read_html.

	s_score_df	ountries_score_df	r cridile (C	ramins-[country (
	Overall rank	Country	Score	GDP per capita	Social support	Healthy life expectancy	Freedom to make life choices	Generosity	Perceptions of corruptions
		Finland	7.809	1.285	1.500	0.961	0.662	0.160	0.4
		Denmark	7.646	1.327	1.503	0.979	0.665	0.243	0.4
		Switzerland	7.560	1.391	1.472	1.041	0.629	0.269	0.4
		Iceland	7.504	1.327	1.548	1.001	0.662	0.362	0.1
		Norway	7.488	1.424	1.495	1.008	0.670	0.288	0.4
148	149	Central African Republic	3.476	0.041	0.000	0.000	0.293	0.254	0.0
149	150	Rwanda	3.312	0.343	0.523	0.572	0.604	0.236	0.4
150		Zimbabwe	3.299	0.426	1.048	0.375	0.377	0.151	0.0
151		South Sudan	2.817	0.289	0.553	0.209	0.066	0.210	0.1
152		Afghanistan	2.567	0.301	0.356	0.266	0.000	0.135	0.0


Keterangan: Mengakses data frame dan mengganti nama kolom country or region menjadi country.

<pre>merged_df = pd.merge(countries_score_df, countries_continent_category_df, how='inner', on='Country') merged_df.to_csv('final_result.csv') merged_df merged_df</pre>											
	Overall rank	Country	Score	GDP per capita	Social support	Healthy life expectancy	Freedom to make life choices	Generosity	Perceptions of corruption	Contine	
		Finland	7.809	1.285	1.500	0.961	0.662	0.160	0.478	Euro	
		Denmark	7.646	1.327	1.503	0.979	0.665	0.243	0.495	Euro	
		Switzerland	7.560	1.391	1.472	1.041	0.629	0.269	0.408	Eur	
		Iceland	7.504	1.327	1.548	1.001	0.662	0.362	0.145	Eur	
		Norway	7.488	1.424	1.495	1.008	0.670	0.288	0.434	Euro	
142	149	Central African Republic	3.476	0.041	0.000	0.000	0.293	0.254	0.028	Afi	
143	150	Rwanda	3.312	0.343	0.523	0.572	0.604	0.236	0.486	Afr	
144		Zimbabwe	3.299	0.426	1.048	0.375	0.377	0.151	0.081	Afi	
145	152	South Sudan	2.817	0.289	0.553	0.209	0.066	0.210	0.111	Afi	
146		Afghanistan	2.567	0.301	0.356	0.266	0.000	0.135	0.001		

Keterangan: Menggabungkan daftar negara dan benua dengan data frame table menggunaman fungsi merge_df dan simpan data di file final_result.csv




Keterangan: Ambil data dari file final_result.csv dengan pd_read_csv dan membuat barcode sederhana.



Keterangan: Membuat histogram menggunakan matplot lib.

```
median_happiness_score = merged_df['Score'].median()
countries_above_median = merged_df.loc[merged_df['Score'] > median_happiness_score]
print(countries_above_median['Country'].to_list())
['Finland', 'Denmark', 'Switzerland', 'Iceland', 'Norway', 'Netherlands', 'Sweden', 'New Zealand', 'Austria', 'Luxembourg', 'Canada', 'Australia', 'United Kingdom', 'Iseland', 'Isel
```

Keterangan: Mencari negara dengan score lebih tinggi dari nilai median.



Keterangan: Mencari korelasi antara score kebahagiaan dengan faktor-faktor lain dengan heatmap.

Hasil: Semakin pekat warna biru maka semakin semakin besar korelasi antara faktor-faktor tersebut. Hipotesa: Tingkat kebahagiaan seseorang atau sebuah negara punya korelasi yang relatif tinggi dengan faktor GDP per capita, Social support dan Healthty life expectancy.

Apakah kaya = Bahagia?



Keterangan: Membuat scaterplot negara dengan GDP per capita sangat tinggi tetapi score kebahagiaan lebih rendah daripada GDP per capita rendah.

Kesimpulan: Uang atau aset yang lebih banyak belum tentu bisa membuat orang lebih bahagia.



Keterangan: Membedakan warna titik berdasarkan benua.